

职业概述

5 年云原生 AI / HPC 平台经验，近 3 年专注大模型推理服务控制面。核心方向是连接推理引擎与业务流量：以 Kubernetes 声明式控制模型服务生命周期和 Router / Worker 就绪，以 OpenAI 兼容 Batch 承载高吞吐离线推理，并通过网关、指标和故障恢复保障生产链路。主要使用 Go / Python。

代表性成果

约 1000 万请求 / 日

生产数据蒸馏与批量生成链路，请求成功率超过 99%

30 万请求 / 97.5 亿 Tokens

SGLang Router 多异构后端压测成功率约 99.9%

从 Pod Ready 到流量可达

用期望状态对账、readiness 与持续 requeue 保证 Router 收敛

工作经历

之江实验室 · 高效能计算设施研究中心

2024 - 至今

高级研究专员 | LLM Serving / MaaS 平台

- 开发 Kubernetes 原生模型服务控制链路，将模型镜像、资源规格、多副本 / P/D 拓扑和服务暴露收敛到 CRD / Controller；完善 Service / Endpoint readiness、finalizer、多集群发布与回滚。
- 改进 Router Worker 管理，以“期望集合 vs. 实际 /workers 集合”持续对账；在缺失、冗余或注册失败时 requeue，避免 Pod Ready 但流量不可达。
- 设计并实现 OpenAI Batch API 兼容执行平台，覆盖文件与 Batch 生命周期、任务切分、分片 Worker 执行、基于 Kubernetes Lease 的选主、租户并发、失败恢复及结果 / 错误回写。
- 支撑日均约 1000 万请求的数据蒸馏链路，成功率超过 99%；完成约 30 万请求、97.5 亿 Tokens 的 SGLang Router 多后端压测，成功率约 99.9%。
- 建设并运营 LiteLLM / Higress 统一模型入口，结合 SGLang / vLLM 处理鉴权限流、模型权限、流式协议与生产故障；沿 request_id → Gateway → Router → Worker → Kubernetes 完成链路定位。

之江实验室 · 智能超算研究中心

2021.08 - 2023

工程专员 | 云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch / 模型适配、分布式任务环境建设和基础性能验证，为后续 GPU / XPU 推理调度与平台化交付奠定基础。

重点系统经历

Kubernetes 原生模型服务控制面

Lifecycle · Reconciliation · Readiness

- 围绕声明式期望状态组织模型服务生命周期：Controller 生成并维护工作负载、Service、路由注册与状态；用 owner / finalizer、健康检查和重试预算保证更新及清理顺序。
- 把“实例已启动”和“服务可接流量”分开验证，联合检查 Pod、Endpoint、模型接口与 Router Worker 集合，并针对注册失败、旧 selector、长连接超时等问题建立恢复路径。
- 参与服务级弹性治理，围绕资源快照、readiness、in-flight 与 cooldown 设计扩缩容门禁；在一项拟议的控制面演进方案中，进一步明确 Planner 容量意图、组件副本执行、集群资源约束和 Router 就绪边界。

重点系统经历（续）

多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 将 Batch 定义为可持久化、可恢复的异步任务，而非批量请求脚本：数据库保存任务真相，Scheduler / Worker 负责 claim、分片、执行、续租和 finalize。 - 通过 Kubernetes Lease、数据库级 claim、租户 / 模型级并发预算和请求级错误隔离支持多副本运行，避免重复执行并降低离线任务对在线服务的冲击。 - 覆盖 JSONL 流式处理、取消、过期清理、output / error 文件和异常 finalizing，形成从 API 契约到生产监控的完整批量执行链路。	
模型网关、路由与推理可靠性	Gateway · Router · Observability
- 基于 LiteLLM / Higress 提供统一 OpenAI 兼容入口，治理 API key、team / model access、TPM / RPM、Token budget、模型映射和请求审计。 - 验证 SGLang / vLLM 的 P/D 拓扑与 Cache-aware 路由，以 QPS、TTFT 和 TPOT 评估性能；定位动态字段破坏共享前缀导致的缓存命中异常。 - 处理生产链路排障与发布验证，覆盖 Router 注册收敛、Service / Endpoint readiness、CrashLoop、流式长连接、多集群配置和回滚。	

核心技术

Serving Control Plane	Go、Kubernetes、CRD / Controller、reconcile、Service / EndpointSlice、readiness、finalizer、Leader Election、Helm、Kustomize、ArgoCD
Inference & Routing	SGLang、vLLM、Router、P/D 分离、KV / Prefix Cache、推理性能指标
Platform & Data Path	Python、Linux、OpenAI-compatible API、LiteLLM、Higress、Prometheus、Redis、MySQL、链路追踪与分布式系统排障
上游架构分析	NVIDIA Dynamo、AIBrix、llm-d：容量意图、副本执行、路由就绪与集群约束边界（源码级评估）

教育背景

亚利桑那州立大学	2019.05 - 2020.12
计算机科学硕士，GPA 3.97 / 4.00	
亚利桑那州立大学	2015.08 - 2019.05
计算机科学本科	

知识产权

授权发明专利 2 项，其中包括“基于云服务的按需扩缩容的模型推理服务系统、方法”；授权软件著作权 2 项。