



赵伟驰

AI 基础设施 / LLM 推理平台工程师

杭州 stefen11wzhao@gmail.com GitHub: WZStephen

求职方向：LLM 推理平台、OpenAI 兼容 MaaS、AI Gateway、Agent Platform、异构 GPU / XPU 调度。

个人简介

面向 AI 基础设施与大模型推理服务的平台工程师，专注生产级 LLM Serving、模型服务控制面和 OpenAI 兼容 MaaS 能力建设。长期参与离线批量推理、模型网关、路由与编排可靠性、Kubernetes 原生推理任务和国产异构 GPU / XPU 环境适配。擅长把科研与模型工作负载沉淀成可复用的平台能力：可观测路由、在线 / 离线流量隔离、灰度与回滚、端到端排障，以及由真实故障驱动的稳定性的加固。

关键成果

- 支撑 BatchFlow 生产数据蒸馏：春节期间累计处理 276 万余条请求 / 约 239 亿 tokens；后续支撑日均约 1000 万条请求，成功率超过 99%。
- 验证 BatchFlow -> SGLang Router -> 多 KLLX 后端链路：Qwen3 负载下约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，BatchFlow 与 Router CPU / 内存开销低于 5%。
- 围绕网关、Router、Worker、Service discovery、readiness 与长连接等多类故障模式加固推理链路可靠性，避免只依赖 Pod 级健康状态判断服务可用性。

核心能力

LLM 推理	SGLang、vLLM、OpenAI 兼容 API、流式响应、Embedding、Responses API、PD 分离、KV / Prefix Cache、Cache-aware 与 Bucket 路由。	MaaS 网关	Higress、LiteLLM、AI Gateway、鉴权、模型映射、Token 级限流、路由同步、指标与可观测性。
控制面	Kubernetes Operator / Controller、CRD、Helm、Kustomize、readiness、finalizer、服务发现、平滑升级、重试与回滚流程。	Agent 平台	私有化 Agent 协议接入、工具调用 API 兼容、Claude / OpenAI 风格适配、工作流安全、本地 Agent 治理。
		工程基础	Go、Python、Java、Linux、Prometheus、MySQL / SQLite / Redis、分布式系统排障、性能压测与容量评估。

工作经历

之江实验室，高效能计算设施研究中心2024 - 至今
高级研究专员，AI 基础设施与 MaaS 平台方向

- 参与建设和运维面向大模型服务的 MaaS 平台能力，覆盖 CPU ACK 与 GPU ACK 跨集群链路，包括 Higress 私有化部署入口、LiteLLM 公共模型入口、SGLang Router 模型路由、IGD / IGDSA 推理任务编排、BatchFlow 离线批处理，以及 Agent 侧 API 兼容。
- 负责多条生产推理链路的问题定位与稳定性优化，处理 Router Worker 注册收敛、Service / Endpoint readiness、PD prefill / decode 拓扑、CrashLoop、长连接超时、网关 Header / 模型映射、多集群平滑上线等问题。
- 参与 MaaS-Controller 与 Optimizer 控制面机制设计，围绕 LiteLLM、Router、IGDSA、BatchFlow、Higress 指标采集与配置下发，设计公共模型限额调整、离线并发调节、观察窗口、回滚条件和在线 SLA 优先等闭环治理机制。

之江实验室，智能超算研究中心2021.08 - 2023
工程专员，云原生 AI / HPC 平台方向

- 参与云原生 AI / HPC 平台建设，包括国产操作系统与加速卡上的 Kubernetes 适配、Device Plugin 定制、PyTorch / 模型适配，以及分布式训练框架与并行策略调研。
- 参与国产异构软硬件环境下的模型训练与推理平台适配，围绕任务提交、资源识别、容器运行环境和基础性能验证，支撑科研项目与平台化能力建设。

重点项目

BatchFlow - OpenAI 兼容离线推理平台	大规模批量推理
面向数据蒸馏、评测、批量生成等非实时任务的异步推理执行面。	
- 设计并实现 OpenAI Batch API 兼容能力，包括文件上传、Batch 生命周期、取消、结果 / 错误文件、流式文件处理、请求级错误隔离和后端并发控制。 - 推动 BatchFlow 向多副本演进，基于 Kubernetes Leader Election 与分片 Worker 改造执行链路，优化 Header 透传、上传限制、过期文件清理、Kustomize 升级、监控和异常 finalizing 容错。 - 支撑生产数据蒸馏任务，春节期间通过 BatchFlow 离线接口累计稳定处理 276 万余条请求，产出约 239 亿 tokens；后续支撑日均约 1000 万条请求处理能力，成功率超过 99%。	

- 完成 BatchFlow -> SGLang Router -> 多 KLX 后端链路压测，在 Qwen3-235B-A22B-Thinking-250T 负载下处理约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，BatchFlow 与 Router CPU / 内存占用低于 5%。

SGLang Router / IGD 推理链路稳定性建设

路由、编排与生产排障

围绕多 Worker、PD 分离和国产异构环境，提升推理任务从部署到请求可达的端到端可靠性。

- 优化 Router Worker 注册与收敛机制，引入“期望集合 vs 实际 /workers 集合”的对账逻辑，在缺失、冗余或注册失败时持续 requeue。
- 完善 IGD / ISI 启动与 readiness：Pod IP 早期注册、`publishNotReadyAddresses`、保留 SLB finalizer、Router 指标 Service，以及带重试预算的 ISI 级自动重启。
- 主导多类生产问题根因分析，包括节点环境变量累积触发 ARG_MAX 导致 Router Pod 启动失败、Worker Ready 后 Router 未纳管、共享 Service selector 残留、45 分钟长连接超时等问题。

MaaS 网关、控制面与 Agent 兼容接入

Higress / LiteLLM / Agent API

统一私有化部署、公共模型服务与离线推理任务的入口、鉴权、路由、协议兼容和观测能力。

- 参与平台分层架构设计，将 Higress 私有入口、LiteLLM 公共入口、SGLang Router、BatchFlow 离线执行面和 MaaS-Controller 控制面拆分为职责清晰的组件。
- 验证 AI Gateway 能力，包括 Token 级限流、模型映射、路由同步、指标采集、OpenAI 兼容协议，以及 Embedding、Responses API 等接口边界。
- 将私有化与公共模型入口映射到 Agent 客户端可使用的 OpenAI 兼容接口，覆盖 Chat Completions、Responses API、Embedding 与工具调用工作流。
- 在用户侧故障处理中从网关、路由、Worker、Service discovery 和模型协议层逐层定位问题，避免只依据顶层 Deployment 或 Pod 状态误判服务健康。

Kubernetes Device Plugin 与异构加速卡平台

GPU / XPU 调度

面向国产异构加速环境的云原生资源发现、调度与验证链路。

- 定制 Device Plugin 与资源管理链路，覆盖加速卡可用性识别、节点资源上报、容器运行时验证、卡级调度和故障隔离。
- 建设 Kubernetes AI / HPC 环境中的部署、升级、回滚和 E2E 验证流程，适配国产操作系统与异构加速卡软件栈。

早期经历

亚利桑那州立大学，SNAC Lab

2020.01 - 2020.08

虚拟平台开发员 / 研究项目助理

- 参与 THOTH Lab 开放式虚拟实验平台开发，扩展 SDN / OpenFlow 教学模块，并基于 Boto3 与 REST API 实现 AWS 实例远程控制能力。
- 基于 IR-CP-ABE 研究论文实现 Android 端网络安全系统原型。

亚利桑那州立大学，CIDSE

2019.08 - 2020.12

研究生服务助理

- 协助 CSE205 面向对象程序设计、CSE412 数据库管理、CSE434 计算机网络、CSE464 软件 QA 与测试课程的教学答疑。

教育背景

亚利桑那州立大学

2019.05 - 2020.12

计算机科学硕士，GPA 3.97 / 4.00

亚利桑那州立大学

2015.08 - 2019.05

计算机科学本科，GPA 3.40 / 4.00