

职业概述

近 5 年云原生 AI / HPC 平台经验，自 2024 年起聚焦 LLM Serving。负责基于 Kubernetes Operator (CRD / Controller 模式) 的 模型服务控制面，覆盖国产异构加速卡上的服务生命周期、P/D 拓扑与容量规划、请求路由和故障恢复；同时交付生产级多租户 Batch 推理、LiteLLM / Higress 模型网关与可观测性。主要使用 Go、Python，具备 Rust 开发经验。

核心技术

Programming: Go、Python、Rust

Control Plane & Scheduling: Kubernetes Operator、CRD / Controller、reconcile、Service / Endpoint、finalizer、Leader Election、异构加速卡资源管理、容量规划与自动扩缩容候选方案、Helm、ArgoCD

LLM Serving & Routing: SGLang、vLLM、P/D 分离、KV Cache、前缀 / 负载感知路由、Mooncake、RoCE/RDMA

Gateway & Batch: OpenAI-compatible API、Batch API、LiteLLM、Higress、Redis、MySQL、多租户准入、离线并发预算与共享后端压力控制

Reliability & Observability: Linux、Prometheus、request tracing、QPS / TTFT / TPOT、发布回滚、故障恢复、分布式系统根因分析

工作经历

之江实验室 2021.08 - 至今

高级研究专员 · 高效能计算设施研究中心 2024 - 至今

LLM Serving / MaaS 平台

- 负责生产级 LLM Serving 控制面，基于 Kubernetes Operator (CRD / Controller) 统一模型服务声明、Worker 生命周期、Service / Endpoint 就绪检查、P/D 拓扑和故障隔离，纳管国产异构加速卡上的 SGLang / vLLM 服务。
- 设计并验证基于请求形状与 Capacity Profile 的 P/D 容量规划与自动扩缩容候选方案，完成 Shadow 与隔离服务扩缩 E2E，并以就绪门禁、稳定窗口、cooldown 和过期校验控制执行风险。
- 交付生产级 OpenAI-compatible 多租户 Batch 推理与 LiteLLM / Higress 模型网关，覆盖持久化分片、并发预算和失败恢复，并通过租户 / 模型并发预算约束离线请求对共享模型后端的压力。
- 负责发布、回滚与生产故障定位，结合 request ID、日志、Prometheus 指标和 Kubernetes 状态排查模型加载、排队、网关路由及异构设备异常。

工程专员 · 智能超算研究中心 2021.08 - 2023

云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch workload / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点工程经历

P/D 容量规划与自动扩缩容候选方案 - 设计基于滑动窗口的候选方案，提取 request rate、输入 / 输出 Token、Prefill compute / cached token、KV hit 信号与队列状态，并按模型、卡型、量化方式、TP / DP 和引擎版本选择 Capacity Profile。 - 在 Shadow 与隔离服务扩缩 E2E 中验证 Prefill / Decode 独立需求和安全副本目标，通过 pending gate、单步变更、稳定窗口、cooldown 与过期校验控制执行风险。	Shadow · Isolated E2E · Guardrails
国产异构卡 P/D 传输与请求路由 - 完成国产异构卡 P/D 功能链路与高速网络传输配置验证：Router 负责 Worker 选择和 Bootstrap / 传输上下文传递，KV Tensor 由传输后端通过 RoCE/RDMA 数据面搬运。 - 实现并验证基于请求前缀相似度与 Worker 负载的选路；负载失衡时切换到最小负载策略，并在关联 Worker 不存在或不健康时清理旧映射；评估 Mooncake 作为 KV 传输后端，并设计 KV-event 驱动的块级路由候选方案。	P/D Validation · RoCE/RDMA · Routing Design
多租户离线批量推理平台 - 以数据库作为任务状态的权威数据源，使用 Kubernetes Lease 选主、事务 claim、分片恢复与 custom_id 去重降低重复处理风险，并校验最终结果完整性。 - 交付 OpenAI Batch API 兼容的 JSONL 流式处理、租户 / 模型并发预算、取消、过期清理、output / error 回写和请求级错误隔离，通过并发预算约束离线请求对共享模型后端的压力。	Production · OpenAI Batch API · Recovery
Rust Router 分级准入与链路追踪 - 在独立 Rust 分支实现并测试 P0-P3 分级准入，通过全局 / 优先级 semaphore、有界队列、严格优先和租户内轮转控制并发，并将 permit 保持到流式响应结束。 - 整合 SGLang HTTP / gRPC P/D 路由与 Bootstrap / 传输上下文；在专用分支实现并验证 request ID 与 trace context 透传，用于跨组件故障定位。	Independent Branch · Priority Admission · Tracing

教育背景

亚利桑那州立大学 - 计算机科学硕士，GPA 3.97 / 4.00，2019.05 - 2020.12
亚利桑那州立大学 - 计算机科学本科，2015.08 - 2019.05

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference，IEEE AIAHPC 2025，第三作者；授权发明专利 2 项、登记软件著作权 2 项。

语言能力

中文（母语）；英语（专业工作沟通）。