

职业概述

5 年云原生 AI / HPC 平台经验，近 3 年聚焦生产级大模型推理系统与调度。主导构建 Kubernetes 原生 LLM Serving Runtime / Control Plane，覆盖 Worker 生命周期与模型加载、KV 事件与请求路由、P/D 容量规划与扩缩容保护机制；并交付 Batch 推理和模型网关。主要使用 Go / Python，具备 Rust 路由开发经验。

工作经历

之江实验室 · 高效能计算设施研究中心

2024 - 至今

高级研究专员 | LLM Serving / MaaS 平台

- 主导分布式推理 Runtime / Control Plane，贯通 Worker Bootstrap、模型快速加载、KV Block 事件、KV-aware Routing、P/D 自适应容量规划和 Kubernetes 生命周期；将“进程已启动”与“模型可服务、事件可观测、流量可达”分层建模。
- 设计并实现可审计的自适应 P/D Planner：融合 request rate、ISL / OSL、Prefill cached / compute tokens、KV hit、queue / running 与 TTFT / TPOT，将实时请求 shape 映射到 Profiler Capacity Profile，分别生成 Prefill / Decode 容量目标和瓶颈侧 ScaleIntent。
- 设计并实现 OpenAI Batch API 兼容执行平台，覆盖文件与 Batch 生命周期、任务切分、分片 Worker 执行、Kubernetes Lease 选主、租户并发、失败恢复及结果 / 错误回写；支撑生产数据蒸馏与批量生成链路日均约 1000 万请求，请求成功率超过 99%。
- 整合 SGLang HTTP / gRPC P/D 路由、多租户准入与链路追踪；对多个异构后端的 SGLang Router 路径完成约 30 万请求、97.5 亿 Tokens 压测，请求成功率约 99.9%，并沿 request_id → Gateway → Router → Worker 定位生产问题。

之江实验室 · 智能超算研究中心

2021 - 2023

工程专员 | 云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch / 模型适配、分布式任务环境建设和基础性能验证，为后续 GPU / XPU 推理调度与平台化交付奠定基础。

重点系统经历

分布式推理 Runtime 与 KV-aware Routing

Worker Bootstrap · ModelExpress · Event Plane

- 将 Worker 启动从“拉起引擎进程”扩展为 Runtime 初始化协议：把引擎生命周期接入 DistributedRuntime，分别注册 request-plane Endpoint 与 Model Deployment Card，发布 WorkerType、依赖 DNF、KV 容量和拓扑元数据；集成 ModelExpress loader，支持扩容阶段的 P2P / NIXL-RDMA 权重分发。
- 在 Bootstrap 阶段为各 DP rank 初始化 KvEventPublisher，将 SGLang / vLLM 原生 BlockStored、BlockRemoved、AllBlocksCleared 事件经 ZMQ 归一化并发布到 Event Plane，维护 Worker KV Block 索引。
- 以请求前缀的 KV overlap、Worker 负载和拓扑约束联合评分；KV 事件不可用时回退到 Token 级近似索引，并通过 Controller 协调 Pod、Endpoint、模型、Event Plane 与 Router readiness。

重点系统经历（续）

自适应 P/D Planner 与扩缩容保护机制	Capacity Profile · ScaleIntent · Guardrails
- 以滑动窗口计算 request rate、输入 / 输出 Token、Prefill compute / cached token 和 KV hit，将实时请求 shape 映射到 Profiler 的 Prefill / Decode 容量曲线，使用区间插值与安全回退避免高估。 - 分别计算 Prefill / Decode token demand、单 Worker 安全吞吐和目标副本，以瓶颈阶段形成 aggregate target；完整保存输入 shape、容量测点、利用率与阻塞原因，支持 Shadow 验证和决策审计。 - 将 Planner、ScaleIntent Controller、ScalingAdapter 与 IGD / ISI / Scheduler 解耦；通过 desired > ready pending gate、单步扩缩、稳定窗口、cooldown 和 stale-intent 校验抑制震荡与并发写入。	
多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 将 Batch 定义为可持久化、可恢复的异步任务，而非批量请求脚本：数据库保存任务真相，Scheduler / Worker 负责 claim、分片、执行、续租和 finalize。 - 通过 Kubernetes Lease、数据库级 claim、租户 / 模型级并发预算和请求级错误隔离支持多副本运行，避免重复执行并降低离线任务对在线服务的冲击。 - 覆盖 JSONL 流式处理、取消、过期清理、output / error 文件和异常 finalizing，形成从 API 契约到生产监控的完整批量执行链路。	
推理 Router 与多租户准入	P/D Routing · Priority Admission · Tracing
- 使用 Rust 实现 P0-P3 分级准入：通过全局 / 优先级 semaphore、严格优先调度、租户内轮转、队列上限与等待超时控制并发，并将 permit 保持到流式 Response Body 结束，避免提前释放容量。 - 整合 SGLang HTTP / gRPC P/D 路由、Prefill / Decode bootstrap 与 transfer context，补齐 request ID 和 trace context 透传；以 QPS、TTFT、TPOT 和 KV 命中验证多后端链路。	

核心技术

Inference Runtime & Routing	SGLang、vLLM、NVIDIA Dynamo、AIBrix、ModelExpress、NIXL / RDMA、KV Event Plane、KV-aware Routing、P/D 分离
Scheduling & Control Plane	Go、Kubernetes、CRD / Controller、Capacity Profile、ScaleIntent、reconcile、readiness、finalizer、Leader Election、Helm、ArgoCD
Gateway & Async Serving	Python、Rust、OpenAI-compatible API、Batch API、LiteLLM、Higress、Redis、MySQL、多租户并发与失败恢复
Observability & Performance	Prometheus、request tracing、QPS / TTFT / TPOT、ISL / OSL、KV hit、吞吐曲线、分布式系统排障

教育背景

亚利桑那州立大学	2019.05 - 2020.12
计算机科学硕士，GPA 3.97 / 4.00	
亚利桑那州立大学	2015.08 - 2019.05
计算机科学本科	

知识产权

授权发明专利 2 项，其中包括“基于云服务的按需扩缩容的模型推理服务系统、方法”；授权软件著作权 2 项。