

## 职业概述

近 5 年云原生 AI / HPC 平台经验，自 2024 年起聚焦生产级 LLM Serving。负责面向国产异构加速卡的分布式推理 Runtime、Rust KV-aware Router、集群内负载感知 Planner 与离线批量推理平台；参与 Kubernetes 原生 MaaS 控制面、KV Event 链路，以及统一网关的调研与接入。主要使用 Go、Python，具备 Rust 工程经验，关注模型服务生命周期、请求路由、容量治理与故障恢复。

## 工作经历

## 之江实验室

2021.08 - 至今

## 高级研究专员 · 高效能计算设施研究中心

2024 - 至今

LLM Serving / MaaS 平台

- 参与 Kubernetes 原生 MaaS 控制面架构与模型服务 CRD 设计，将模型、资源规格和服务形态收敛为统一声明，支持模板化一键部署；负责推理实例池、状态与 Endpoint 聚合，并承担生产发布和故障排查。
- 负责自研分布式推理 Runtime，完成 SGLang Engine Adapter、推理实例注册发现及生命周期管理，统一模型发布、拓扑协作、分层就绪和扩缩容摘流。
- 负责集群内负载感知 Planner 与 Rust KV-aware Router：结合实时负载、队列、KV 状态和离线容量画像计算副本目标，并基于 Prefix KV overlap、推理实例负载及健康状态完成请求调度。
- 独立设计并实现生产级离线批量推理平台；参与统一网关的技术调研与接入，覆盖模型接入、配置验证和跨组件生产排障。

## 工程专员 · 智能超算研究中心

2021.08 - 2023

云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch workload / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

## 重点生产系统

## 模型服务控制面与分布式推理 Runtime

Declarative Serving · Runtime · Readiness

- 参与统一模型服务 CRD 与 Controller 建设，将模型、资源规格、服务形态和访问入口收敛为声明式交付模板，支持模型服务一键部署；控制面管理期望状态，Runtime 发布实际服务能力。
- 负责 SGLang Engine Adapter、推理实例注册发现与模型发布链路，统一拓扑协作、分层就绪和生命周期管理，隔离引擎内部接口与上层平台。
- 扩容实例在完整就绪并注册后进入流量池；缩容时先摘流，再等待在途请求结束并注销 Endpoint，故障实例可被隔离，减少人工配置和跨组件排障成本。

## KV-aware Router 与 KV Event 链路

Rust Routing · KV Event · Prefix Index

- 使用 Rust 实现 KV-aware Router，在同一模型与卡型服务域内综合 Prefix KV overlap、推理实例实时负载、队列和健康状态选择目标实例，接入 SGLang HTTP 与 gRPC 请求链路。
- 负责 KV Event Adapter、ZMQ → NATS Event Bridge 及 Router 事件消费与 Prefix 索引，将 BlockStored、BlockRemoved、AllBlocksCleared 标准化为 Stored、Removed、Cleared RouterEvent。
- 根据持续更新的 Prefix 索引在缓存局部性与实时负载之间权衡，并在推理实例异常时将其移出候选集，支持稳定的请求重选与调度。

重点生产系统（续）

集群内负载感知的 P/D Planner

Capacity Modeling · Replica Autoscaling · Observability

- 汇聚集群内 Router、推理实例与 Prometheus 实时指标，结合请求负载、队列、KV 状态和离线容量画像持续计算模型服务副本目标。
- 对 P/D 分离服务分别计算 Prefill、Decode 副本，对聚合服务统一计算副本；Planner 负责容量决策，控制面与 Kubernetes 负责资源创建和最终调度。
- 生产运行中在压力升高时成功扩容并降低队列积压，使请求恢复稳定；负载回落后自动回收空闲副本，提高集群资源利用率。

多租户离线批量推理平台

OpenAI Batch API · Scheduling · Recovery

- 面向数据蒸馏、数据生成和评测等大规模离线任务，实现 OpenAI Batch API、JSONL 流式处理、任务分片、并发控制以及 output / error 结果汇总。
- 通过持久化任务进度、Kubernetes Lease 选主和分片重新认领，使调度器或执行实例异常后能够从已有进度继续执行，避免整批任务重跑。
- 采用至少一次后端执行与结果级去重，结合 custom\_id 跳过已落盘请求，实现请求级错误隔离和长期稳定运行。

核心技术

Runtime & Data Plane: 分布式推理 Runtime、SGLang、KV Event Plane、ZMQ / NATS、P/D 分离

Control Plane & Scheduling: Go、Kubernetes Operator、CRD / Controller、推理实例池、容量画像、P/D 副本弹性伸缩、Device Plugin、Helm、ArgoCD

Routing & Gateway: Rust、KV-aware Routing、HTTP / gRPC 路由、Prefix Index、LiteLLM 调研与接入、OpenAI / Anthropic API、认证与限流配置

Batch & Observability: Python、OpenAI Batch API、Redis、MySQL、Kubernetes Lease、Prometheus、QPS / TTFT / TPOT、request tracing

教育背景

亚利桑那州立大学 - 计算机科学硕士，GPA 3.97 / 4.00，2019.05 - 2020.12

亚利桑那州立大学 - 计算机科学本科，2015.08 - 2019.05

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference, IEEE AIAHPC 2025, 第三作者；授权发明专利 2 项、登记软件著作权 2 项。

语言能力

中文（母语）；英语（专业工作沟通）。