

职业概述

近 5 年云原生 AI / HPC 平台经验，自 2024 年起聚焦生产级 LLM Serving。主导国产异构加速卡环境的 Kubernetes 原生 MaaS 控制面，落地声明式模型服务编排、Dynamo Runtime、P/D Planner、KV Event Plane、Mooncake RDMA KV 传输与 KV-aware Router；同时建设 BatchFlow、LiteLLM / Higress 模型网关、弹性伸缩、故障恢复和可观测性。主要使用 Go、Python，具备 Rust 工程经验。

工作经历

之江实验室

2021.08 - 至今

高级研究专员 · 高效能计算设施研究中心

2024 - 至今

LLM Serving / MaaS 平台

- 主导生产级 Kubernetes 原生 MaaS 控制面，将国产异构加速卡上的聚合与 P/D 分离服务抽象为声明式模型服务，由 Controller 自动编排 Worker、Router、Service 与 Ingress，统一生命周期、故障隔离和扩缩入口，降低多组件手工部署与适配复杂度。
- 将 SGLang / vLLM Worker 接入 Dynamo DistributedRuntime，贯通 Worker Bootstrap、KV Event Plane、Mooncake KV 数据面和 KV-aware Router，使服务发现、请求路由、KV 复用与 P/D 传输形成完整 Runtime 链路。
- 建设生产级 P/D Planner，基于请求形状、KV 命中与容量画像计算 Prefill / Decode 副本目标，通过可审计扩缩决策、就绪门禁、稳定窗口、cooldown 和回滚保护闭环执行。
- 交付 BatchFlow 多租户离线推理、LiteLLM / Higress 模型网关与 Rust Router；负责发布回滚和生产故障定位，以 request ID、Prometheus 指标及 Kubernetes 状态贯通排队、路由、传输和服务就绪观测。

工程专员 · 智能超算研究中心

2021.08 - 2023

云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch workload / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点生产系统

模型服务控制面与 Dynamo Runtime

Declarative Serving · Service Discovery · Readiness

- 以统一模型服务 CRD 作为生命周期入口，声明聚合 / P/D 分离拓扑、组件规格、运行策略与网络入口；Controller 持续编排 Worker、Router、Service 与 Ingress，并聚合服务状态和访问入口，将多资源手工配置收敛为一个声明式交付入口。
- 将 Worker 接入 Dynamo DistributedRuntime，统一服务发现、实际引擎能力发布与 P/D Bootstrap；控制面维护期望状态，Worker 发布角色、并发能力、KV 布局和服务 Endpoint，避免静态配置覆盖运行时事实。
- 只有模型健康、KV Event、Mooncake 传输通道、P/D Bootstrap 和 Router 注册全部就绪才接收流量；缩容时先停止新准入，再等待在途请求完成并注销 Endpoint，避免流式请求被直接切断。

KV Event Plane 与 Mooncake KV 数据面

KV-aware Routing · RDMA KV Transfer · Fallback

- 按 DP rank 消费 SGLang / vLLM 的 BlockStored、BlockRemoved、AllBlocksCleared 事件并归一化到 Event Plane，维护 Worker / Rank / Storage Tier 维度的 Prefix Radix Index。
- Router 综合 prefix KV overlap、Worker 负载、卡型 / KV 布局兼容性和网络拓扑选择 P/D Worker；Mooncake Transfer Engine 基于高性能网络通过 RDMA 批量传输 KV Tensor，事件异常时降级到负载策略，传输异常时执行超时摘除、重选和重试。

重点生产系统（续）

自适应 P/D Planner 与扩缩容保护机制	Capacity Modeling · P/D Autoscaling · Guardrails
- 以滑动窗口聚合 request rate、ISL / OSL、Prefill 计算 Token / 缓存 Token、KV hit、队列和运行状态，并按模型、卡型、量化方式、TP / DP 及引擎版本选择 Capacity Profile，以插值和保守回退计算安全容量。 - 分别计算 Prefill / Decode token demand、单 Worker 安全吞吐和副本目标，以瓶颈阶段形成 aggregate target；持续输出可审计扩缩决策，保存输入 shape、容量测点、利用率和阻塞原因。 - 解耦容量决策、扩缩执行、模型服务 Controller 与 Kubernetes Scheduler；通过 desired > ready pending gate、单步扩缩、稳定窗口、cooldown、过期决策校验和失败回滚抑制震荡及并发写入。	
KV-aware Router、多租户准入与链路追踪	P/D Routing · Priority Admission · Tracing
- 整合 SGLang HTTP / gRPC P/D 路由，基于 KV overlap、Worker 负载、兼容性和网络拓扑选择 Prefill / Decode Worker，透传 request ID、Bootstrap / Transfer Context 与 KV telemetry，用于跨组件故障定位。 - 使用 Rust 实现 P0-P3 分级准入，通过全局 / 优先级 semaphore、有界队列、严格优先、租户内轮转与等待超时控制并发，并将 permit 保持到流式 Response Body 结束，避免容量提前释放。	
BatchFlow 多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 将 Batch 定义为可持久化、可恢复的异步任务：数据库作为任务状态权威源，Scheduler / Worker 负责事务 claim、分片、续租和 finalize，并通过 Kubernetes Lease、custom_id 去重和分片恢复支撑多副本运行。 - 交付 OpenAI Batch API 兼容的 JSONL 流式处理、租户 / 模型并发预算、取消、过期清理、output / error 回写及请求级错误隔离，限制离线任务对共享在线模型后端的压力。	

核心技术

Runtime & Data Plane: Dynamo Runtime / DistributedRuntime、SGLang、vLLM、KV Event Plane、Mooncake Transfer Engine、RDMA KV 传输、P/D 分离
Control Plane & Scheduling: Go、Kubernetes Operator、CRD / Controller、声明式模型服务编排、容量画像、P/D Autoscaling、Device Plugin、Helm、ArgoCD
Routing & Admission: KV-aware Routing、Rust、HTTP / gRPC P/D 路由、Prefix Radix Index、P0-P3 准入、流式请求生命周期
Serving & Observability: Python、OpenAI-compatible API、Batch API、LiteLLM、Higress、Redis、MySQL、Prometheus、QPS / TTFT / TPOT、request tracing

教育背景

亚利桑那州立大学 - 计算机科学硕士，GPA 3.97 / 4.00，2019.05 - 2020.12
亚利桑那州立大学 - 计算机科学本科，2015.08 - 2019.05

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference，IEEE AIAHPC 2025，第三作者；授权发明专利 2 项、登记软件著作权 2 项。

语言能力

中文（母语）；英语（专业工作沟通）。