

职业概述

近 5 年云原生 AI / HPC 平台经验，自 2024 年起聚焦生产级 LLM Serving。核心负责推理引擎与业务流量之间的平台层建设，具备从 Kubernetes 声明式控制面、SGLang Runtime、Rust KV-aware Router、集群内 P/D 容量规划到离线批量推理的端到端实践；能够围绕请求成功率、TTFT、TPOT、吞吐、队列水位和可服务容量构建服务验收与优化闭环。主要使用 Go、Python，具备 Rust 工程经验。

工作经历

之江实验室

2021.08 - 至今

高级研究专员 · 高效能计算设施研究中心

2024 - 至今

LLM Serving / MaaS 平台

- 参与 Kubernetes 原生 MaaS 控制面架构与模型服务 CRD 设计，将模型、资源规格和服务形态收敛为统一声明，支持模板化一键部署；负责推理实例池、状态与 Endpoint 聚合，并承担生产发布和故障排查。
- 核心负责面向国产异构加速卡的在线推理链路，打通 SGLang Runtime、KV-aware 路由与集群内容量决策，形成从实例状态感知、就绪判断、请求调度到副本调整的服务闭环。
- 独立设计并实现生产级离线批量推理平台，支撑数据蒸馏、数据生成与评测任务；参与统一网关调研与接入，完成模型接入、配置验证及跨组件生产排障。

工程专员 · 智能超算研究中心

2021.08 - 2023

云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch workload / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点生产系统

模型服务控制面与分布式推理 Runtime

Declarative Serving · Runtime · Readiness

- 参与统一模型服务 CRD 与 Controller 建设，将模型、资源规格、服务形态和访问入口收敛为声明式模板，打通从服务声明、资源编排、状态聚合到 Endpoint 发布的一键部署链路。
- 负责 SGLang Engine Adapter、推理实例注册发现与模型发布链路，统一拓扑协作、分层就绪和生命周期管理，隔离引擎内部接口与上层平台。
- 构建分层可用性门控与优雅上下线机制：扩容实例仅在引擎就绪、完成注册后接入流量；缩容先摘流、等待在途请求结束再注销 Endpoint，并隔离故障实例。

KV-aware Router 与 KV Event 链路

Rust Routing · KV Event · Prefix Index

- 使用 Rust 实现 KV-aware Router，将 Prefix KV overlap、实时负载、队列与健康状态统一纳入调度，在同一模型与卡型的服务域内完成请求级实例选择，并接入 SGLang HTTP / gRPC 链路。
- 打通 KV Event Adapter、ZMQ → NATS Event Bridge、Router 事件消费与 Prefix 索引链路，将引擎 KV Cache 状态转化为实时路由索引，形成从 Block 事件到请求调度的数据闭环。

重点生产系统（续）

集群内负载感知的 P/D Planner	Capacity Modeling · Replica Autoscaling · Observability
- 构建集群内负载感知 Planner，汇聚 Router、推理实例与 Prometheus 实时指标，结合请求负载、队列、KV 状态和离线容量画像持续计算服务副本目标。 - 对 P/D 分离服务分别计算 Prefill、Decode 副本，对聚合服务统一计算副本；Planner 负责容量决策，控制面与 Kubernetes 负责资源创建和最终调度。 - 打通生产环境负载感知、容量决策、弹性伸缩与效果回读闭环；以请求成功率、TTFT / TPOT、队列水位和可服务容量为核心指标，验证高负载扩容与负载回落缩容。	
多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 面向数据蒸馏、数据生成和评测等大规模长任务，对外兼容 OpenAI Batch API；用户提交 JSONL 后，平台自动完成流式解析、任务分片、并发调度和结果汇总。 - 通过持久化任务进度、Kubernetes Lease 选主和分片重新认领，使调度器或执行实例异常后能够从已有进度继续执行，避免整批任务重跑。 - 采用至少一次后端执行与结果级去重，结合 custom_id 跳过已落盘请求，实现请求级错误隔离和长期稳定运行。	

核心技术

Runtime & Data Plane: 分布式推理 Runtime、SGLang、KV Event Plane、ZMQ / NATS、P/D 分离
Control Plane & Scheduling: Go、Kubernetes Operator、CRD / Controller、推理实例池、容量画像、P/D 副本弹性伸缩、Device Plugin、Helm、ArgoCD
Routing & Gateway: Rust、KV-aware Routing、HTTP / gRPC 路由、Prefix Index、LiteLLM 调研与接入、OpenAI / Anthropic API、认证与限流配置
Batch & Observability: Python、OpenAI Batch API、Redis、MySQL、Kubernetes Lease、Prometheus、QPS / TTFT / TPOT、request tracing

教育背景

亚利桑那州立大学 - 计算机科学硕士，GPA 3.97 / 4.00，2019.05 - 2020.12
亚利桑那州立大学 - 计算机科学本科，2015.08 - 2019.05

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference, IEEE AIAHPC 2025, 第三作者；授权发明专利 2 项、登记软件著作权 2 项。

语言能力

中文（母语）；英语（专业工作沟通）。