



赵伟驰

AI 基础设施 / LLM 推理平台工程师

杭州 wzhao4z@outlook.com GitHub: WZStephen 个人主页: wzstephen.github.io

求职方向: LLM 推理平台、OpenAI 兼容 MaaS、AI Gateway、Agent Platform、异构 GPU / XPU 调度。

个人简介

面向 AI 基础设施与大模型推理服务的平台工程师，专注生产级 LLM Serving、模型服务控制面和 OpenAI 兼容 MaaS 能力建设。长期参与公共模型服务、离线批量推理、模型网关、路由与编排可靠性、Agent 客户端接入、Kubernetes 原生推理任务和国产异构 GPU / XPU 环境适配。擅长把科研与模型工作负载沉淀成可复用的平台能力，并将 Claude Code、Codex、OpenCode、OpenClaw 等 Agent 工具链嵌入日常研发、排障和文档流程，提升代码定位、方案整理和验证闭环效率。

关键成果

- 支撑 BatchFlow 生产数据蒸馏：春节期间累计处理 276 万余条请求 / 约 239 亿 tokens；后续支撑日均约 1000 万条请求，成功率超过 99%。
- 验证 BatchFlow -> SGLang Router -> 多 KLLX 后端链路：Qwen3 负载下约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，BatchFlow 与 Router CPU / 内存开销低于 5%。
- 建设 OpenAI 兼容 MaaS 公共服务能力，围绕 API key、模型授权、TPM / RPM、token budget、模型映射和 Agent 客户端接入沉淀可复用治理流程。
- 将 Agent 辅助工作流用于代码检索、故障复盘、方案草稿、发布核对和文档沉淀，把多步人工流程模板化、可复用化，显著减少重复检索与初稿整理时间。
- 围绕网关、Router、Worker、Service discovery、readiness 与长连接等多类故障模式加固推理链路可靠性，避免只依赖 Pod 级健康状态判断服务可用性。

核心能力

LLM 推理	SGLang、vLLM、OpenAI 兼容 API、流式响应、Embedding、Responses API、PD 分离、KV / Prefix Cache、Cache-aware 与 Bucket 路由。	MaaS 公共服务	Higress、LiteLLM、AI Gateway、API key、team / model access、TPM / RPM、token budget、模型映射、指标与可观测性。
控制面	Kubernetes Operator / Controller、CRD、Helm、Kustomize、readiness、finalizer、服务发现、平滑升级、重试与回滚流程。	Agent 平台	Claude Code / Codex / OpenCode 接入、工具调用 API 兼容、OpenAI / Anthropic 风格适配、长上下文缓存优化、Agent 辅助研发工作流。
		工程基础	Go、Python、Java、Linux、Prometheus、MySQL / SQLite / Redis、分布式系统排障、性能压测与容量评估。

工作经历

之江实验室，高效能计算设施研究中心 2024 - 至今
高级研究专员，AI 基础设施与 MaaS 平台方向

- 参与建设和运维面向大模型服务的 MaaS 平台能力，覆盖 CPU ACK 与 GPU ACK 跨集群链路，包括公共模型服务入口、OpenAI 兼容 API、Higress / LiteLLM 网关、SGLang Router 模型路由、IGD / IGDSA 推理任务编排、BatchFlow 离线批处理，以及 Agent 侧 API 兼容。
- 负责多条生产推理链路的问题定位与稳定性优化，处理 Router Worker 注册收敛、Service / Endpoint readiness、PD prefill / decode 拓扑、CrashLoop、长连接超时、网关 Header / 模型映射、多集群平滑上线等问题。
- 参与 MaaS-Controller 与 Optimizer 控制面机制设计，围绕 LiteLLM、Router、IGDSA、BatchFlow、Higress 指标采集与配置下发，设计公共模型限额调整、离线并发调节、观察窗口、回滚条件和在线 SLA 优先等闭环治理机制。

之江实验室，智能超算研究中心 2021.08 - 2023
工程专员，云原生 AI / HPC 平台方向

- 参与云原生 AI / HPC 平台建设，包括国产操作系统与加速卡上的 Kubernetes 适配、Device Plugin 定制、PyTorch / 模型适配，以及分布式训练框架与并行策略调研。
- 参与国产异构软硬件环境下的模型训练与推理平台适配，围绕任务提交、资源识别、容器运行环境和基础性能验证，支撑科研项目与平台化能力建设。

重点项目

BatchFlow - OpenAI 兼容离线推理平台 大规模批量推理
面向数据蒸馏、评测、批量生成等非实时任务的异步推理执行面。

- 设计并实现 OpenAI Batch API 兼容能力，包括文件上传、Batch 生命周期、取消、结果 / 错误文件、流式文件处理、请求级错误隔离和后端并发控制。

- 推动 BatchFlow 向多副本演进，基于 Kubernetes Leader Election 与分片 Worker 改造执行链路，优化 Header 透传、上传限制、过期文件清理、Kustomize 升级、监控和异常 finalizing 容错。
- 支撑生产数据蒸馏任务，春节期间通过 BatchFlow 离线接口累计稳定处理 276 万余条请求，产出约 239 亿 tokens；后续支撑日均约 1000 万条请求处理能力，成功率超过 99%。
- 完成 BatchFlow -> SGLang Router -> 多 KLX 后端链路压测，在 Qwen3-235B-A22B-Thinking-2507 负载下处理约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，BatchFlow 与 Router CPU / 内存占用低于 5%。

SGLang Router / IGD 推理链路稳定性建设

路由、编排与生产排障

围绕多 Worker、PD 分离和国产异构环境，提升推理任务从部署到请求可达的端到端可靠性。

- 优化 Router Worker 注册与收敛机制，引入“期望集合 vs 实际 /workers 集合”的对账逻辑，在缺失、冗余或注册失败时持续 requeue。
- 完善 IGD / ISI 启动与 readiness：Pod IP 早期注册、`publishNotReadyAddresses`、保留 SLB finalizer、Router 指标 Service，以及带重试预算的 ISI 级自动重启。
- 主导多类生产问题根因分析，包括节点环境变量累积触发 ARG_MAX 导致 Router Pod 启动失败、Worker Ready 后 Router 未纳管、共享 Service selector 残留、45 分钟长连接超时等问题。

MaaS 公共模型服务与 Agent 接入优化

OpenAI-compatible API / Agent Runtime

面向内部用户、Agent 客户端和离线任务的统一模型接入、鉴权、限流、协议兼容、成本治理和排障链路。

- 建设 OpenAI 兼容公共模型服务入口，统一 Chat Completions、Responses API、Embedding、Batch API 与 Agent 客户端接入，屏蔽底层不同模型服务、Router 和异构集群差异。
- 参与公共服务治理能力建设，围绕 API key、team、model access、quota、TPM / RPM、token budget、模型映射和成本控制配置模型访问权限与限流策略。
- 梳理 Claude Code / Codex 类 Agent 客户端的协议兼容边界，覆盖 system prompt、tools schema、tool_result、streaming event、Responses API 与 OpenAI / Anthropic 风格字段差异。
- 定位 Claude Code 长上下文请求下 SGLang prefix / KV cache 命中率低的问题，通过对比渲染 prompt、cached-token 日志和 token longest common prefix，确认动态 attribution 字段污染请求前缀并规避。
- 将 Agent 工具链嵌入日常工程流程，用于跨仓代码定位、日志线索归纳、设计方案草稿、PR / issue 文案、发布核对和知识库沉淀，提升复杂任务的上下文整合与交付效率。
- 建立 Agent 接入 MaaS 公共服务的排障流程，从 API key、模型权限、quota、max_tokens、限流、连接超时、网关转发、Router / Worker 状态和模型协议层逐级定位问题。

Kubernetes Device Plugin 与异构加速卡平台

GPU / XPU 调度

面向国产异构加速环境的云原生资源发现、调度与验证链路。

- 定制 Device Plugin 与资源管理链路，覆盖加速卡可用性识别、节点资源上报、容器运行时验证、卡级调度和故障隔离。
- 建设 Kubernetes AI / HPC 环境中的部署、升级、回滚和 E2E 验证流程，适配国产操作系统与异构加速卡软件栈。

早期经历

亚利桑那州立大学，SNAC Lab

虚拟平台开发员 / 研究项目助理

2020.01 - 2020.08

- 参与 THOTH Lab 开放式虚拟实验平台开发，扩展 SDN / OpenFlow 教学模块，并基于 Boto3 与 REST API 实现 AWS 实例远程控制能力。
- 基于 IR-CP-ABE 研究论文实现 Android 端网络安全系统原型。

亚利桑那州立大学，CIDSE

研究生服务助理

2019.08 - 2020.12

- 协助 CSE205 面向对象程序设计、CSE412 数据库管理、CSE434 计算机网络、CSE464 软件 QA 与测试课程的教学答疑。

教育背景

亚利桑那州立大学

计算机科学硕士，GPA 3.97 / 4.00

2019.05 - 2020.12

亚利桑那州立大学

计算机科学本科，GPA 3.40 / 4.00

2015.08 - 2019.05