



赵伟驰

AI 基础设施工程师 | LLM 推理平台 / MaaS / Kubernetes

杭州 stefen11wzhao@gmail.com GitHub: WZStephen

求职方向：AI Infra、大模型推理平台、云原生模型服务、AI Gateway、异构算力调度与平台工程。

个人简介

面向 AI 基础设施与大模型推理服务的平台工程师，长期参与 MaaS、LLM Serving、模型网关、离线批处理、Kubernetes Operator 和国产异构算力环境建设。擅长把模型服务从“能跑起来”推进到“可接入、可观测、可调度、可恢复、可产品化”：明确控制面与数据面边界，建设 OpenAI 兼容入口，治理在线与离线流量，围绕 Router、Worker、网关、存储和 Kubernetes 资源做端到端排障与稳定性优化。

核心能力

LLM 推理	SGLang、vLLM、OpenAI 兼容 API、流式响应、Embedding、Responses API 兼容性、PD 分离、KV Cache 感知路由。	网关与治理	Higress、Envoy / WASM 理念、LiteLLM、鉴权、模型映射、Token 级限流、路由同步、指标与可观测性。
平台工程	Kubernetes、Operator / Controller、CRD、Helm、Kustomize、平滑升级、服务发现、GPU 推理任务生命周期管理。	工程基础	Go、Python、Java、Linux、Prometheus、MySQL / SQLite / Redis、分布式系统排障、性能压测与容量评估。

工作经历

之江实验室，高效能计算设施研究中心 高级研究专员，AI 基础设施与 MaaS 平台方向	2024 - 至今
- 参与建设和运维面向大模型服务的 MaaS 平台能力，覆盖 CPU ACK 与 GPU ACK 跨集群链路，包括 Higress 私有化部署入口、LiteLLM 公共模型入口、SGLang Router 模型路由、IGD / IGDSA 推理任务编排，以及 BatchFlow 离线批处理。 - 负责多条生产推理链路的问题定位与稳定性优化，处理 Router Worker 注册收敛、Service / Endpoint readiness、PD prefill / decode 拓扑、CrashLoop、长连接超时、网关 Header / 模型映射、多集群平滑上线等问题。 - 参与 MaaS-Controller 与 Optimizer 控制面设计，围绕 LiteLLM、Router、IGDSA、BatchFlow、Higress 指标采集与配置下发，设计在线 SLA 优先、离线并发调节、观察窗口、回滚条件等闭环治理机制。	
之江实验室，智能超算研究中心 工程专员，云原生 AI / HPC 平台方向	2021.08 - 2023
- 参与云原生 AI / HPC 平台建设，包括国产操作系统与加速卡上的 Kubernetes 适配、Device Plugin 定制、PyTorch / 模型适配，以及分布式训练框架与并行策略调研。 - 参与国产异构软硬件环境下的模型训练与推理平台适配，围绕任务提交、资源识别、容器运行环境和基础性能验证，支撑科研项目与平台化能力建设。	

重点项目

BatchFlow - OpenAI 兼容离线推理平台	大规模批量推理
面向数据蒸馏、评测、批量生成等非实时任务的异步推理执行面。 - 设计并实现 OpenAI Batch API 兼容能力，包括文件上传、Batch 创建、状态查询、取消、结果 / 错误文件、流式文件处理、请求级错误隔离和后端并发控制。 - 推动 BatchFlow 从单实例向多副本形态演进，基于 Kubernetes Leader Election 与分片 Worker 改造调度执行链路，优化 Header 透传、上传限制、过期文件清理、Kustomize 平滑升级、监控展示和异常 finalizing / validating 容错逻辑。 - 支撑生产数据蒸馏任务，春节期间通过 BatchFlow 离线接口累计稳定处理 276 万余条请求，产出约 239 亿 tokens；后续支撑日均约 1000 万条请求处理能力，成功率超过 99%。 - 完成 BatchFlow -> SGLang Router -> 多 KLX 后端链路压测，在 Qwen3-235B-A22B-Thinking-2507 负载下处理约 30 万请求、约 97.5 亿 tokens，成功率约 99.9%，BatchFlow 与 Router 自身 CPU / 内存占用低于 5%。	
SGLang Router / IGD 推理链路稳定性建设	路由、编排与生产排障
围绕多 Worker、PD 分离和国产异构环境，提升推理任务从部署到请求可达的端到端可靠性。 - 优化 Router Worker 注册与收敛机制，引入“期望集合 vs 实际 /workers 集合”的对账逻辑，在缺失、冗余或注册失败时持续 requeue，避免部分 Worker 长期未纳管的隐性故障。 - 完善 IGD / ISI 在 Router 启动阶段的 readiness 处理，优先使用 Pod IP 完成注册，为 Service 启用 `publishNotReadyAddresses`，保留 SLB finalizer，并为 Router 指标端口自动生成 Prometheus Service。	

6/5/26, 5:00 PM

赵伟驰 - AI 基础设施简历

- 开发并验证 ISI 级自动重启能力，新增显式开关、重启计数、失败原因、failure fingerprint、重试预算和失败资源清理逻辑，同时兼容存量任务，降低新特性上线风险。
- 主导多类生产问题根因分析，包括节点环境变量累积触发 ARG_MAX 导致 Router Pod 启动失败、Worker Ready 后 Router 未纳管、共享 Service selector 残留、45 分钟长连接超时等问题。

MaaS 网关与控制面集成

Higress / LiteLLM / 指标治理

统一私有化部署、公共模型服务与离线推理任务的入口、鉴权、路由和观测能力。

- 参与平台分层架构设计，将 Higress 私有任务入口、LiteLLM 公共模型入口、SGLang Router 路由层、BatchFlow 离线执行面和 MaaS-Controller 控制面拆分为职责清晰的组件。
- 调研和验证 AI Gateway 能力，包括 Token 级限流、模型映射、路由同步、指标采集、OpenAI 兼容协议处理，以及 Embedding、Responses API 等新接口的兼容边界。
- 在用户侧故障处理中从网关、路由、Worker、Service discovery 和模型协议层逐层定位问题，避免只依据顶层 Deployment 或 Pod 状态误判服务健康。

早期经历

亚利桑那州立大学，SNAC Lab

2020.01 - 2020.08

虚拟平台开发员 / 研究项目助理

- 参与 THOTH Lab 开放式虚拟实验平台开发，扩展 SDN / OpenFlow 教学模块，并基于 Boto3 与 REST API 实现 AWS 实例远程控制能力。
- 基于 IR-CP-ABE 研究论文实现 Android 端网络安全系统原型。

亚利桑那州立大学，CIDSE

2019.08 - 2020.12

研究生服务助理

- 协助 CSE205 面向对象程序设计、CSE412 数据库管理、CSE434 计算机网络、CSE464 软件 QA 与测试课程的教学答疑。

教育背景

亚利桑那州立大学

2019.05 - 2020.12

计算机科学硕士，GPA 3.97 / 4.00

亚利桑那州立大学

2015.08 - 2019.05

计算机科学本科，GPA 3.40 / 4.00

最后更新：2026 年 6 月