

职业概述

近 5 年云原生 AI / HPC 平台经验，自 2024 年起聚焦生产级 LLM Serving。负责面向国产异构加速卡的分布式推理 Runtime、Rust KV-aware Router、P/D Planner 与离线批量推理平台；参与 Kubernetes 原生 MaaS 控制面、KV Event / Mooncake 传输链路和 LiteLLM 模型网关建设。主要使用 Go、Python，具备 Rust 工程经验，关注模型服务生命周期、请求路由、容量治理与故障恢复。

工作经历

之江实验室

2021.08 - 至今

高级研究专员 · 高效能计算设施研究中心

2024 - 至今

LLM Serving / MaaS 平台

- 参与 Kubernetes 原生 MaaS 控制面架构与模型服务 CRD 设计，负责 P/D 分离及 Prefill / Decode Worker 池化的 Controller 逻辑、Worker 状态与 Endpoint 聚合，并承担生产发布和故障排查。
- 负责自研分布式推理 Runtime，参考 Dynamo 的服务发现与 P/D 分离架构，完成 SGLang / vLLM 引擎 Adapter、Worker 注册发现及扩缩容摘流，统一模型发布、P/D Bootstrap 与分层就绪状态。
- 负责 P/D Planner 与 Rust KV-aware Router：结合多集群实时负载、队列、KV 状态和离线容量画像计算副本目标，并基于 Prefix KV overlap、Worker 负载及健康状态完成 P/D Worker 选择。
- 独立设计并实现生产级离线批量推理平台；参与 KV Event / Mooncake 链路及 LiteLLM 模型网关建设，覆盖统一 API、认证限流、监控和跨组件生产排障。

工程专员 · 智能超算研究中心

2021.08 - 2023

云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch workload / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点生产系统

模型服务控制面与分布式推理 Runtime

Declarative Serving · Runtime · Readiness

- 参与统一模型服务 CRD 与 Controller 建设，将聚合 / P/D 分离拓扑、Worker 池、Service 与 Ingress 收敛为声明式交付入口；控制面负责期望状态，Runtime 发布实际服务能力，Planner 只计算副本目标。
- 负责 SGLang / vLLM 引擎 Adapter、Worker 注册发现与模型发布链路，参考 Dynamo 架构统一 P/D Bootstrap 和分层就绪状态，但不直接依赖或改造 Dynamo Runtime。
- 扩容 Worker 在完整就绪并注册后进入流量池；缩容时先摘流，再等待在途请求结束并注销 Endpoint，故障 Worker 可被隔离，减少人工配置和跨组件排障成本。

KV-aware Router 与 KV Event / Mooncake 链路

Rust Routing · KV Event · Mooncake Transfer

- 使用 Rust 实现 KV-aware Router，在同一模型与卡型服务域内综合 Prefix KV overlap、Worker 实时负载、队列和健康状态选择 Prefill / Decode Worker，接入 SGLang / vLLM HTTP 与 gRPC 请求链路。
- 负责 KV Event Adapter、ZMQ→NATS Event Bridge 及 Router 事件消费与 Prefix 索引，将 BlockStored、BlockRemoved、AllBlocksCleared 标准化为 Stored、Removed、Cleared RouterEvent。
- Router 只传递 Bootstrap / Transfer Context，KV Tensor 由 Mooncake Transfer Engine 在 P/D Worker 间直接传输；生产链路支持故障 Worker 摘除、异常重选和稳定请求处理。

重点生产系统（续）

多集群负载感知的 P/D Planner

Capacity Modeling · Replica Autoscaling · Observability

- 汇聚多个集群的 Router、Worker 与 Prometheus 实时指标，结合请求负载、队列、KV 状态和离线容量画像持续计算模型服务副本目标。
- 对 P/D 分离服务分别计算 Prefill、Decode 副本，对聚合服务统一计算副本；Planner 负责容量决策，控制面与 Kubernetes 负责资源创建和最终调度。
- 生产运行中在压力升高时成功扩容并降低队列积压，使请求恢复稳定；负载回落后自动回收空闲副本，提高集群资源利用率。

多租户离线批量推理平台

OpenAI Batch API · Scheduling · Recovery

- 独立实现 OpenAI Batch API、持久化任务状态机、Scheduler / Worker、JSONL 流式处理、任务分片、租户 / 模型并发控制、取消及 output / error 回写，统一管理数据蒸馏任务生命周期。
- Redis 负责待处理分片竞争与分发，数据库保存 Batch、Shard 和 Claim 权威状态；Scheduler 通过 Kubernetes Lease 选主，Worker Claim 过期后可被其他副本重新认领。
- 结合共享结果文件与 custom_id 跳过已落盘请求，采用至少一次后端执行与结果级去重边界，实现故障恢复、请求级错误隔离和长期稳定运行。

核心技术

Runtime & Data Plane: 分布式推理 Runtime、SGLang、vLLM、KV Event Plane、ZMQ / NATS、Mooncake Transfer Engine、P/D 分离

Control Plane & Scheduling: Go、Kubernetes Operator、CRD / Controller、Worker 池、容量画像、P/D 副本弹性伸缩、Device Plugin、Helm、ArgoCD

Routing & Gateway: Rust、KV-aware Routing、HTTP / gRPC P/D 路由、Prefix Index、LiteLLM、OpenAI / Anthropic API、认证与限流

Batch & Observability: Python、OpenAI Batch API、Redis、MySQL、Kubernetes Lease、Prometheus、QPS / TTFT / TPOT、request tracing

教育背景

亚利桑那州立大学 - 计算机科学硕士，GPA 3.97 / 4.00，2019.05 - 2020.12

亚利桑那州立大学 - 计算机科学本科，2015.08 - 2019.05

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference，IEEE AIAHPC 2025，第三作者；授权发明专利 2 项、登记软件著作权 2 项。

语言能力

中文（母语）；英语（专业工作沟通）。