

职业概述

5 年云原生 AI / HPC 平台经验，近 3 年聚焦生产级 LLM Serving。负责国产异构加速卡环境的 Kubernetes 原生控制面，覆盖模型服务生命周期、P/D 拓扑与容量治理、Mooncake / RoCE KV 传输和 KV-aware Routing；同时交付多租户 Batch 推理、模型网关与生产可观测性。主要使用 Go / Python，具备 Rust 路由开发经验。

工作经历

之江实验室 · 高效能计算设施研究中心

2024 - 至今

高级研究专员 | LLM Serving / MaaS 平台

- 负责国产异构加速卡推理平台控制面，统一模型服务声明、Worker 生命周期、P/D 拓扑、分层就绪与故障隔离，使不同卡型及 SGLang / vLLM 后端通过同一 MaaS 接口稳定交付。
- 建设基于 Capacity Profile 的生产容量治理，将实时请求形状映射为 Prefill / Decode 独立容量目标，并通过就绪门禁、稳定窗口与冷却机制形成可审计的扩缩容闭环。
- 交付 OpenAI-compatible Batch 与模型网关，覆盖任务持久化、分片执行、多租户准入、失败恢复和全链路追踪，长期支撑生产数据蒸馏与批量生成任务。

之江实验室 · 智能超算研究中心

2021 - 2023

工程专员 | 云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点系统经历

国产异构卡 Runtime 与 KV-aware Routing

Worker Bootstrap · KV Event · Mooncake / RoCE

- 将进程、模型、KV 事件、Mooncake / RoCE 数据通道和流量就绪拆成独立状态；只有模型加载、P/D Bootstrap、传输通道和 Router 注册全部完成后，Worker 才进入可服务集合。
- 由 KV Event Plane 维护缓存位置元数据，Mooncake Transfer Engine 通过 RoCE 搬运实际 KV Tensor，避免让 Router 承载 KV 数据传输。
- Router 综合前缀重叠、Worker 负载、卡型兼容性与网络拓扑选路；事件过期或传输异常时摘除不可用 P/D Pair，并回退到健康链路。

自适应 P/D Planner 与扩缩容保护机制	Capacity Profile · ScaleIntent · Guardrails
- 从滑动窗口提取 request rate、输入 / 输出 Token、Prefill compute / cached token、KV hit 与队列状态，按模型、卡型、量化方式、TP / DP 和引擎版本选择独立 Capacity Profile。 - 分别计算 Prefill / Decode 需求与安全副本目标，以瓶颈阶段形成扩缩意图；保存请求形状、容量测点与阻塞原因，并通过 pending gate、单步扩缩、稳定窗口、cooldown 和过期校验抑制振荡。	
多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 以数据库保存任务真相，Scheduler / Worker 负责 claim、分片、执行、续租和 finalize；通过 Kubernetes Lease、请求级错误隔离与异常 finalizing 支持多副本恢复，避免重复执行。 - 覆盖 JSONL 流式处理、租户 / 模型并发预算、取消、过期清理及 output / error 回写，形成从 OpenAI Batch API 契约到生产监控的完整链路，并降低离线任务对在线服务的影响。	
推理 Router 与多租户准入	P/D Routing · Priority Admission · Tracing
- 使用 Rust 实现 P0-P3 分级准入，通过全局 / 优先级 semaphore、有界队列、严格优先和租户内轮转控制并发；将 permit 保持到流式响应结束，避免提前释放容量。 - 整合 SGLang HTTP / gRPC P/D 路由并传递 bootstrap / transfer context；KV 数据由 Mooncake / RoCE 直传，同时贯通 request ID、trace context、队列与 KV 传输指标。	

核心技术

Inference Runtime & Routing	SGLang、vLLM、Mooncake Transfer Engine、RoCE / RDMA、KV Event Plane、KV-aware Routing、P/D 分离
Scheduling & Control Plane	Go、Kubernetes、CRD / Controller、Capacity Profile、P/D Autoscaling、reconcile、readiness、Leader Election、Helm、ArgoCD
Gateway & Async Serving	Python、Rust、OpenAI-compatible API、Batch API、LiteLLM、Higress、Redis、MySQL、多租户并发与失败恢复
Observability & Performance	Prometheus、request tracing、QPS / TTFT / TPOT、ISL / OSL、KV hit / transfer、吞吐曲线、分布式系统排障

教育背景

亚利桑那州立大学	2019.05 - 2020.12
计算机科学硕士，GPA 3.97 / 4.00	
亚利桑那州立大学	2015.08 - 2019.05
计算机科学本科	

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference, IEEE AIAHPC 2025, 第三作者；授权发明专利 2 项、软件著作权 2 项。