

职业概述

5 年云原生 AI / HPC 平台经验，近 3 年聚焦生产级大模型推理系统与调度。主导在国产异构加速卡环境构建 Kubernetes 原生 LLM Serving Runtime / Control Plane，覆盖 Worker 生命周期、Mooncake / RoCE KV 数据面、KV-aware Routing、P/D 容量规划与扩缩容；并交付多租户 Batch 推理和模型网关。主要使用 Go / Python，具备 Rust 路由开发经验。

工作经历

之江实验室 · 高效能计算设施研究中心

2024 - 至今

高级研究专员 | LLM Serving / MaaS 平台

- 主导国产异构卡分布式推理 Runtime / Control Plane，贯通 Worker Bootstrap、模型加载、KV Event Plane、Mooncake / RoCE KV 传输、KV-aware Routing、P/D 自适应容量规划和 Kubernetes 生命周期；将进程、模型、事件、数据通道和流量就绪分层建模。
- 设计并落地可审计的生产 P/D Planner：融合 request rate、ISL / OSL、Prefill cached / compute tokens、KV hit、queue / running 与 TTFT / TPOT，按模型、卡型、量化方式和并行策略选择 Capacity Profile，分别生成 Prefill / Decode 容量目标和 ScaleIntent。
- 设计并实现 OpenAI Batch API 兼容执行平台，覆盖文件与 Batch 生命周期、任务切分、分片 Worker 执行、Kubernetes Lease 选主、租户并发、失败恢复及结果 / 错误回写；长期支撑生产数据蒸馏与批量生成任务。
- 整合 SGLang HTTP / gRPC P/D 路由、多租户准入与链路追踪，在多个国产异构后端稳定运行；贯通 request_id → Gateway → Router → Worker，并围绕 KV 传输、排队与 Worker 状态定位生产问题。

之江实验室 · 智能超算研究中心

2021 - 2023

工程专员 | 云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点系统经历

国产异构卡 Runtime 与 KV-aware Routing

Worker Bootstrap · KV Event · Mooncake / RoCE

- 将 Worker 启动从进程拉起扩展为 Runtime 初始化协议：把引擎生命周期接入 DistributedRuntime，分别注册 request-plane Endpoint 与 Model Deployment Card，并发布卡型、WorkerType、P/D 角色、依赖 DNF、KV 容量和 RoCE 拓扑元数据。
- 在各 DP rank 初始化 KvEventPublisher，将 SGLang / vLLM 原生 BlockStored、BlockRemoved、AllBlocksCleared 事件归一化到 Event Plane；实际 KV Tensor 由 Mooncake Transfer Engine 通过 RoCE 在 Prefill / Decode 间传输。
- 综合请求前缀 KV overlap、Worker 负载、卡型兼容性和网络拓扑评分；事件不可用时回退到 Token 级近似索引，并由 Controller 协调模型、Event Plane、Mooncake / RoCE 通道与 Router readiness。

自适应 P/D Planner 与扩缩容保护机制	Capacity Profile · ScaleIntent · Guardrails
- 以滑动窗口计算 request rate、输入 / 输出 Token、Prefill compute / cached token 和 KV hit；按模型、卡型、量化方式、TP / DP 与引擎版本选择 Prefill / Decode Capacity Profile，使用区间插值与安全回退避免高估。 - 分别计算 Prefill / Decode token demand、单 Worker 安全吞吐和目标副本，以瓶颈阶段形成 aggregate target；持续输出生产 ScaleIntent，并完整保存输入 shape、容量测点、利用率与阻塞原因用于决策审计。 - 将 Planner、ScaleIntent Controller、ScalingAdapter 与 IGD / ISI / Scheduler 解耦；通过 desired > ready pending gate、单步扩缩、稳定窗口、cooldown 和 stale-intent 校验抑制震荡与并发写入。	
多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 将 Batch 定义为可持久化、可恢复的异步任务，而非批量请求脚本：数据库保存任务真相，Scheduler / Worker 负责 claim、分片、执行、续租和 finalize。 - 通过 Kubernetes Lease、数据库级 claim、租户 / 模型级并发预算和请求级错误隔离支持多副本运行，避免重复执行并降低离线任务对在线服务的冲击。 - 覆盖 JSONL 流式处理、取消、过期清理、output / error 文件和异常 finalizing，形成从 API 契约到生产监控的完整批量执行链路。	
推理 Router 与多租户准入	P/D Routing · Priority Admission · Tracing
- 使用 Rust 实现 P0-P3 分级准入：通过全局 / 优先级 semaphore、严格优先调度、租户内轮转、队列上限与等待超时控制并发，并将 permit 保持到流式 Response Body 结束，避免提前释放容量。 - 整合 SGLang HTTP / gRPC P/D 路由，选择兼容的 Prefill / Decode Worker 并传递 bootstrap / transfer context；KV 数据由 Mooncake / RoCE 直传，同时贯通 request ID、trace context 与传输可观测性。	

核心技术

Inference Runtime & Routing	SGLang、vLLM、Mooncake Transfer Engine、RoCE / RDMA、KV Event Plane、KV-aware Routing、P/D 分离、Dynamo / AIBrix 架构
Scheduling & Control Plane	Go、Kubernetes、CRD / Controller、Capability / Capacity Profile、ScaleIntent、reconcile、readiness、finalizer、Leader Election、Helm、ArgoCD
Gateway & Async Serving	Python、Rust、OpenAI-compatible API、Batch API、LiteLLM、Higress、Redis、MySQL、多租户并发与失败恢复
Observability & Performance	Prometheus、request tracing、QPS / TTFT / TPOT、ISL / OSL、KV hit、KV transfer、吞吐曲线、分布式系统排障

教育背景

亚利桑那州立大学	2019.05 - 2020.12
计算机科学硕士，GPA 3.97 / 4.00	
亚利桑那州立大学	2015.08 - 2019.05
计算机科学本科	

知识产权

授权发明专利 2 项，其中包括“基于云服务的按需扩缩容的模型推理服务系统、方法”；授权软件著作权 2 项。