



赵伟驰

AI Infra / MaaS / LLM Serving 平台工程师

杭州 wzhao4z@outlook.com GitHub: WZStephen 个人主页: wzstephen.github.io

求职方向: LLM Serving、OpenAI 兼容 MaaS、AI Gateway、Kubernetes 模型部署、离线推理与数据蒸馏。

个人简历

聚焦大模型服务生产化链路，覆盖 Kubernetes 一键部署、OpenAI 兼容 MaaS、LiteLLM / Higress 网关、SGLang Router、离线推理和数据蒸馏。长期参与公共模型服务、推理框架适配、模型网关、路由可靠性、Agent 客户端接入和国产 GPU / XPU 环境适配，关注模型能力如何从“能跑起来”变成“可交付、可治理、可观测、可恢复”的平台能力。

关键成果

- 支撑生产数据蒸馏链路，日均约 1000 万条请求，成功率超过 99%，沉淀任务切分、并发控制、失败恢复和结果回写机制。
- 验证离线批量推理 -> SGLang Router -> 多异构后端链路：Qwen3 负载下约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，平台与 Router CPU / 内存开销低于 5%。
- 参与 SGLang / vLLM / Dynamo 推理框架调优：覆盖 KV / Prefix Cache、PD 分离、Cache-aware / Bucket 路由和 QPS / TTFT / Tok/s 验证。
- 基于 LiteLLM / Higress 等开源网关能力建设 OpenAI 兼容 MaaS 公共服务，解决多模型接入、鉴权限流、模型权限、用量统计和故障定位问题。
- 在当前 MaaS / LLM Serving 工作中使用 Agent 辅助代码检索、故障复盘、方案草稿、发布核对和文档沉淀，把多步人工流程沉淀为可复用迭代链路。
- 围绕 Kubernetes 原生一键部署完善推理任务生命周期，覆盖 CRD / Controller、Service / Endpoint、readiness、Router 发现、指标 Service、finalizer、多集群上线和回滚。

成果与荣誉

- 参与授权发明专利 2 项、授权软著 2 项；所在团队相关荣誉包括中国青年五四奖章集体、全国工人先锋号和 Gordon Bell Prize 团队荣誉。

核心能力

LLM 推理	SGLang、vLLM、OpenAI 兼容 API、流式响应、Embedding、Responses API、PD 分离、KV / Prefix Cache、Cache-aware 与 Bucket 路由。	MaaS 公共服务	Higress、LiteLLM、AI Gateway、API key、team / model access、TPM / RPM、token budget、模型映射、指标与可观测性。
模型部署	Kubernetes 原生推理任务、Operator / Controller、CRD、Helm、Kustomize、Service / Endpoint、readiness、finalizer、平滑升级与回滚。	Agent 平台	Claude Code / Codex / OpenCode 接入、工具调用 API 兼容、OpenAI / Anthropic 风格适配、长上下文缓存优化、Agent 辅助工程迭代。
		工程基础	Go、Python、Linux、Prometheus、MySQL / SQLite / Redis、分布式系统排障、性能压测与容量评估。

工作经历

- 之江实验室，高效能计算设施研究中心

高级研究专员，AI Infra 与 MaaS 平台方向

2024 - 至今

 - 参与建设和运维面向大模型服务的 MaaS 平台能力，覆盖公共模型服务入口、OpenAI 兼容 API、Higress / LiteLLM 开源网关接入、SGLang / vLLM 框架适配、Kubernetes 原生一键部署、SGLang Router、离线批量推理和 Agent 侧 API 兼容。
 - 负责多条生产推理链路的问题定位与稳定性优化，处理模型部署生命周期、Router Worker 注册收敛、Service / Endpoint readiness、PD prefill / decode 拓扑、CrashLoop、长连接超时、网关 Header / 模型映射和多集群上线等问题。
 - 参与 MaaS 控制面与优化闭环机制设计，围绕 LiteLLM、Router、离线批量推理、Higress 指标采集与配置下发，设计公共模型限额调整、离线并发调节、观察窗口、回滚条件和在线 SLA 优先等治理机制。
- 之江实验室，智能超算研究中心

工程专员，云原生 AI / HPC 平台方向

2021.08 - 2023

 - 参与云原生 AI / HPC 平台建设，包括国产操作系统与加速卡上的 Kubernetes 适配、Device Plugin 定制、PyTorch / 模型适配，以及分布式训练框架与并行策略调研。
 - 参与国产异构软硬件环境下的模型训练与推理平台适配，围绕任务提交、资源识别、容器运行环境和基础性能验证，支撑科研项目与平台化能力建设。

重点项目

- OpenAI 兼容离线批量推理平台

大规模批量推理

面向数据蒸馏、评测、批量生成等非实时任务的异步推理执行面。

 - 设计并实现 OpenAI Batch API 兼容能力，包括文件上传、Batch 生命周期、取消、结果 / 错误文件、流式文件处理、请求级错误隔离和后端并发控制。

- 推动平台向多副本演进，基于 Kubernetes Leader Election 与分片 Worker 改造执行链路，优化 Header 透传、上传限制、过期文件清理、Kustomize 升级、监控和异常 finalizing 容错。
- 支撑生产数据蒸馏和批量生成任务，后续达到日均约 1000 万条请求处理能力，成功率超过 99%。
- 完成离线批量推理 -> SGLang Router -> 多异构后端链路压测，在 Qwen3-235B-A22B-Thinking-2507 负载下处理约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，平台与 Router CPU / 内存占用低于 5%。

Kubernetes 原生一键部署与推理链路稳定性建设

模型部署、调优、路由与生产排障

把模型、镜像、资源、端口、健康检查、Service、worker 注册和接口验证标准化，提升模型从配置到请求可达的端到端可靠性。

- 参与 Kubernetes 原生推理任务生命周期编排，覆盖模型镜像、启动参数、资源规格、多副本拓扑、Service / Endpoint、readiness、Router 发现、指标 Service、finalizer 和回滚路径，减少人工拼 YAML 带来的交付和排障成本。
- 参与 SGLang / vLLM / Dynamo 调研与适配验证，梳理 PagedAttention / RadixAttention、KV Cache、Prefix Cache、PD 分离、多级缓存复用、上下文长度、并发、batch 和 cache 命中率等调优边界。
- 优化 Router Worker 注册与收敛机制，引入“期望集合 vs 实际 /workers 集合”的对账逻辑，在缺失、冗余或注册失败时持续 requeue。
- 完善推理实例启动与 readiness：Pod IP 早期注册、`publishNotReadyAddresses`、保留 Service finalizer、Router 指标 Service，以及带重试预算的实例级自动重启。
- 参与 Cache-aware / Bucket 等调度策略验证，并定位节点环境变量累积、Worker Ready 后 Router 未纳管、共享 Service selector 残留、长连接超时等生产问题。

MaaS 公共模型服务与 Agent 接入优化

OpenAI-compatible API / Agent Runtime

基于 LiteLLM / Higress 等开源网关能力，面向内部用户、Agent 客户端和离线任务提供统一模型接入、鉴权、限流、协议兼容、成本治理和排障链路。

- 建设 OpenAI 兼容公共模型服务入口，统一 Chat Completions、Responses API、Embedding、Batch API 与 Agent 客户端接入，屏蔽底层不同模型服务、Router 和异构集群差异，避免业务直接感知后端实例。
- 参与公共服务治理能力建设，围绕 API key、team、model access、quota、TPM / RPM、token budget、模型映射和成本控制配置模型访问权限与限流策略。
- 梳理 Claude Code / Codex 类 Agent 客户端协议兼容边界，覆盖 system prompt、tools schema、tool_result、streaming event、Responses API 与 OpenAI / Anthropic 字段差异。
- 定位 Claude Code 长上下文请求下 SGLang prefix / KV cache 命中率低的问题，通过对比渲染 prompt、cached-token 日志和 token LCP，确认动态 attribution 字段污染请求前缀并规避。
- 将 Agent 工具链嵌入跨仓代码定位、日志归纳、方案草稿、PR / issue 文案、发布核对、知识库沉淀和 MaaS 接入排障，缩短复杂平台任务反馈链路。

Kubernetes Device Plugin 与异构加速卡平台

GPU / XPU 调度

面向国产异构加速环境的云原生资源发现、调度与验证链路。

- 定制 Device Plugin 与资源管理链路，覆盖加速卡可用性识别、节点资源上报、容器运行时验证、卡级调度和故障隔离。
- 建设 Kubernetes AI / HPC 环境中的部署、升级、回滚和 E2E 验证流程，适配国产操作系统与异构加速卡软件栈。

早期经历

亚利桑那州立大学，SNAC Lab 虚拟平台开发员 / 研究项目助理	2020.01 - 2020.08
• 参与 THOTH Lab 开放式虚拟实验平台开发，扩展 SDN / OpenFlow 教学模块，并基于 Boto3 / REST API 实现 AWS 实例远程控制；曾实现 Android 端网络安全系统原型。	
亚利桑那州立大学，CIDSE 研究生服务助理	2019.08 - 2020.12
• 协助 CSE205、CSE412、CSE434、CSE464 等课程教学答疑。	

教育背景

亚利桑那州立大学 计算机科学硕士，GPA 3.97 / 4.00	2019.05 - 2020.12
亚利桑那州立大学 计算机科学本科，GPA 3.40 / 4.00	2015.08 - 2019.05