

职业概述

近 5 年云原生 AI / HPC 平台经验，自 2024 年起聚焦生产级 LLM Serving。主导国产异构加速卡环境的 Kubernetes 原生 MaaS 控制面，落地 Dynamo Runtime、P/D Planner、KV Event Plane、Mooncake RDMA KV 传输、KV-aware Router 与模型快速加载；同时建设 BatchFlow、LiteLLM / Higress 模型网关、弹性伸缩、故障恢复和可观测性。主要使用 Go、Python，具备 Rust 工程经验。

工作经历

之江实验室

2021.08 - 至今

高级研究专员 · 高效能计算设施研究中心

2024 - 至今

LLM Serving / MaaS 平台

- 主导生产级 LLM Serving 平台与 Kubernetes Operator 控制面，将国产异构加速卡上的 SGLang / vLLM Worker 接入 Dynamo DistributedRuntime，统一模型服务声明、Worker 生命周期、P/D 拓扑、分层就绪与故障隔离。
- 贯通 Worker Bootstrap、KV Event Plane、Mooncake KV 数据面和 KV-aware Router，并落地 ModelExpress 分层模型快载，使请求路由、KV 复用与弹性扩容形成完整 Runtime 链路。
- 建设生产级 P/D Planner，基于请求形状、KV 命中与 Capacity Profile 计算 Prefill / Decode 副本目标，通过 ScaleIntent、就绪门禁、稳定窗口、cooldown 和回滚保护闭环执行。
- 交付 BatchFlow 多租户离线推理、LiteLLM / Higress 模型网关与 Rust Router；负责发布回滚和生产故障定位，以 request ID、Prometheus 指标及 Kubernetes 状态贯通排队、路由、传输和模型加载观测。

工程专员 · 智能超算研究中心

2021.08 - 2023

云原生 AI / HPC 平台

- 定制 Kubernetes Device Plugin 与资源管理链路，完成异构加速卡发现、节点资源上报、容器运行时验证、卡级分配和故障隔离。
- 面向国产操作系统与异构加速器开展 PyTorch workload / 模型适配、分布式任务环境建设和基础性能验证，为后续国产异构推理调度与平台化交付奠定基础。

重点生产系统

Dynamo Runtime 与 ModelExpress 分层模型快速加载

DistributedRuntime · Tiered Cache · Readiness

- 在生产环境落地基于 Dynamo DistributedRuntime 的 SGLang / vLLM Runtime，统一 Worker 生命周期、Namespace / Component / Endpoint 服务发现、ModelRuntimeConfig / ModelDeploymentCard 注册、P/D Bootstrap 与优雅摘流；以进程、模型、KV Event、传输通道和 Router 注册组成分层 Ready Gate。
- 生产落地 ModelExpress 分层快载：以 model revision、dtype、量化方式、TP / EP 拓扑和厂商 Runtime 构成不可变兼容键，按兼容 READY Worker 设备内存、节点 NVMe、CPFS / NFS 选择加载源，结合预取、预分片、并行加载与 cache-aware 调度降低扩容冷启动开销。
- 通过 Lease 去重、checksum 校验、原子发布及厂商 JIT / 算子 / 图缓存复用保障一致性；完成权重校验、warmup、健康检查、KV Event 和 Router 注册后才接流量，异常时回退至 NVMe、共享存储或 native loader。

KV Event Plane 与 Mooncake KV 数据面

KV-aware Routing · RDMA KV Transfer · Fallback

- 按 DP rank 消费 SGLang / vLLM 的 BlockStored、BlockRemoved、AllBlocksCleared 事件并归一化到 Event Plane，维护 Worker / Rank / Storage Tier 维度的 Prefix Radix Index。
- Router 综合 prefix KV overlap、Worker 负载、卡型 / KV 布局兼容性和网络拓扑选择 P/D Worker；Mooncake Transfer Engine 基于高性能网络通过 RDMA 批量传输 KV Tensor，事件异常时降级到负载策略，传输异常时执行超时摘除、重选和重试。

重点生产系统（续）

自适应 P/D Planner 与扩缩容保护机制	Capacity Profile · ScaleIntent · Guardrails
- 以滑动窗口聚合 request rate、ISL / OSL、Prefill 计算 Token / 缓存 Token、KV hit、队列和运行状态，并按模型、卡型、量化方式、TP / DP 及引擎版本选择 Capacity Profile，以插值和保守回退计算安全容量。 - 分别计算 Prefill / Decode token demand、单 Worker 安全吞吐和副本目标，以瓶颈阶段形成 aggregate target；持续输出可审计 ScaleIntent，保存输入 shape、容量测点、利用率和阻塞原因。 - 解耦 Planner、ScaleIntent Controller、ScalingAdapter 与 IGD / ISI / Scheduler；通过 desired > ready pending gate、单步扩缩、稳定窗口、cooldown、stale-intent 校验和失败回滚抑制震荡及并发写入。	
KV-aware Router、多租户准入与链路追踪	P/D Routing · Priority Admission · Tracing
- 整合 SGLang HTTP / gRPC P/D 路由，基于 KV overlap、Worker 负载、兼容性和网络拓扑选择 Prefill / Decode Worker，透传 request ID、Bootstrap / Transfer Context 与 KV telemetry，用于跨组件故障定位。 - 使用 Rust 实现 P0-P3 分级准入，通过全局 / 优先级 semaphore、有界队列、严格优先、租户内轮转与等待超时控制并发，并将 permit 保持到流式 Response Body 结束，避免容量提前释放。	
BatchFlow 多租户离线批量推理平台	OpenAI Batch API · Scheduling · Recovery
- 将 Batch 定义为可持久化、可恢复的异步任务：数据库作为任务状态权威源，Scheduler / Worker 负责事务 claim、分片、续租和 finalize，并通过 Kubernetes Lease、custom_id 去重和分片恢复支撑多副本运行。 - 交付 OpenAI Batch API 兼容的 JSONL 流式处理、租户 / 模型并发预算、取消、过期清理、output / error 回写及请求级错误隔离，限制离线任务对共享在线模型后端的压力。	

核心技术

Runtime & Data Plane: Dynamo Runtime / DistributedRuntime、SGLang、vLLM、KV Event Plane、Mooncake Transfer Engine、RDMA KV 传输、P/D 分离
Control Plane & Scheduling: Go、Kubernetes Operator、CRD / Controller、Capability / Capacity Profile、ScaleIntent、P/D Autoscaling、Device Plugin、Helm、ArgoCD
Model Loading & Routing: ModelExpress、CPFS / NFS、node-local NVMe、pre-sharded checkpoint、cache-aware scheduling、KV-aware Routing、Rust
Serving & Observability: Python、OpenAI-compatible API、Batch API、LiteLLM、Higress、Redis、MySQL、Prometheus、QPS / TTFT / TPOT、request tracing

教育背景

亚利桑那州立大学 - 计算机科学硕士，GPA 3.97 / 4.00，2019.05 - 2020.12
亚利桑那州立大学 - 计算机科学本科，2015.08 - 2019.05

论文与知识产权

Prompt2Length: A Lightweight Model for Predicting Output Length in LLM Inference，IEEE AIAHPC 2025，第三作者；授权发明专利 2 项、登记软件著作权 2 项。

语言能力

中文（母语）；英语（专业工作沟通）。