



赵伟驰

大模型推理平台与资源调度工程师

杭州 wzhao4z@outlook.com GitHub: WZStephen 个人主页: wzstephen.github.io

求职方向: LLM Serving / MaaS Control Plane、Kubernetes 模型服务、推理资源调度与流量治理。

个人简历

5 年云原生 AI / HPC 平台经验，近 2 年聚焦大模型推理平台与 MaaS 控制面。围绕 Kubernetes 原生模型服务生命周期、Router / Worker 收敛、在线流量治理、离线批量推理和网关治理，持续推进从模型部署、流量接入到批量执行和故障恢复的生产链路；具备 SGLang / vLLM 性能验证及 Dynamo Planner / Grove 架构研究经验，关注推理 SLA、资源利用率与单位 Token 成本。

关键成果

- 完善 Kubernetes 原生模型服务控制链路，覆盖 CRD / Controller、Service / Endpoint、readiness、Router Worker 发现与收敛、finalizer、多集群上线和回滚。
- 参与 MaaS 调度与优化闭环设计，围绕流量、队列、Worker 状态和在线 SLA，梳理容量意图、离线并发调节、观察窗口与回滚边界。
- 支撑生产数据蒸馏链路，日均约 1000 万条请求，成功率超过 99%，沉淀任务切分、并发控制、失败恢复和结果回写机制。
- 完成离线批量推理 -> SGLang Router -> 多异构后端链路压测：约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，平台与 Router CPU / 内存开销低于 5%。
- 基于 LiteLLM / Higress 建设 OpenAI 兼容 MaaS 服务入口，覆盖多模型接入、鉴权限流、模型权限、用量治理和故障定位。

核心能力

模型服务控制面

Kubernetes、Operator / Controller、CRD、Helm、Kustomize、服务生命周期、Service / Endpoint、readiness、Worker 发现、升级与回滚。

MaaS 与流量治理

Higress、LiteLLM、AI Gateway、OpenAI / Anthropic 协议、API key、模型权限、TPM / RPM、token budget、流式请求与可观测性。

推理调度与性能

SGLang、vLLM、PD 分离、KV / Prefix Cache、Cache-aware / Bucket 路由、QPS / TTFT / TPOT / Tok/s、性能压测与容量评估。

离线批量推理

OpenAI Batch API、任务切分、队列与并发控制、Leader Election、分片 Worker、失败恢复、结果回写和多租户隔离。

工程与异构资源

Go、Python、Linux、Prometheus、Redis、Device Plugin、GPU / XPU 资源发现、分布式系统排障和生产发布验证。

工作经历

之江实验室，高效能计算设施研究中心

高级研究专员，AI Infra 与 MaaS 平台方向

2024 - 至今

- 推进 Kubernetes 原生模型服务与 MaaS 公共服务建设，覆盖 CRD / Controller 生命周期、SGLang / vLLM 适配、Router Worker 管理、OpenAI 兼容网关和离线批量推理。
- 承担多条生产推理链路的故障定位与稳定性改进，闭环 Service / Endpoint readiness、PD prefill / decode 拓扑、Router 注册收敛、CrashLoop、长连接超时和多集群发布问题。
- 参与 MaaS 调度与优化闭环设计，基于网关流量、离线队列、Worker 状态和在线 SLA，梳理容量意图、公共模型限额、离线并发调节、观察窗口及回滚条件。

之江实验室，智能超算研究中心

工程专员，云原生 AI / HPC 平台方向

2021.08 - 2023

- 参与云原生 AI / HPC 平台建设，包括国产操作系统与加速卡上的 Kubernetes 适配、Device Plugin 定制、PyTorch / 模型适配，以及分布式训练框架与并行策略调研。
- 参与国产异构软硬件环境下的模型训练与推理平台适配，围绕任务提交、资源识别、容器运行环境和基础性能验证，支撑科研项目与平台化能力建设。

重点项目

Kubernetes 原生模型服务控制面与推理调度

MaaS Control Plane / Model Serving

以 CRD / Controller 承载模型服务意图，打通工作负载、服务发现、Router 收敛、弹性治理与生产发布链路。

- 参与模型服务生命周期编排，覆盖镜像与启动参数、资源规格、多副本 / PD 拓扑、Service / Endpoint、readiness、指标 Service、finalizer 及回滚路径。
- 优化 Router Worker 注册与收敛机制，引入“期望集合 vs 实际 /workers 集合”对账，在缺失、冗余或注册失败时持续 requeue，避免 Worker Ready 但流量不可达。
- 完善实例启动与服务发现链路，包括 Pod IP 早期注册、`publishNotReadyAddresses`、Service 生命周期保护，以及带重试预算的实例级自动恢复。
- 围绕流量、队列、Worker 稳定性和在线 SLA 参与调度策略设计与验证，并参考 Dynamo Planner / Global Planner / Grove 源码，明确容量意图、资源预算、执行收敛、离线并发调节和安全回滚边界。

OpenAI 兼容离线批量推理与调度平台	大规模离线推理
面向数据蒸馏、模型评测和批量生成任务，建设异步执行、并发治理、失败恢复与结果回写能力。	
- 设计并实现 OpenAI Batch API 兼容能力，包括文件上传、Batch 生命周期、取消、结果 / 错误文件、流式文件处理、请求级错误隔离和后端并发控制。 - 推动平台向多副本演进，基于 Kubernetes Leader Election 与分片 Worker 改造执行链路，完善租户并发治理、监控、过期文件清理和异常 finalizing 容错。 - 支撑生产数据蒸馏和批量生成任务，达到日均约 1000 万条请求处理能力，成功率超过 99%。 - 完成离线批量推理 -> SGLang Router -> 多异构后端链路压测，在 Qwen3 负载下处理约 30 万请求 / 97.5 亿 tokens，成功率约 99.9%，平台与 Router CPU / 内存占用低于 5%。	
MaaS 网关与推理流量治理	AI Gateway / Router
面向在线服务与离线任务提供统一模型入口、访问控制、流量治理、协议兼容和全链路故障定位。	
- 基于 LiteLLM / Higress 建设 OpenAI 兼容模型服务入口，统一 Chat Completions、Responses API、Embedding 与 Batch API，屏蔽底层 Router、模型实例和异构集群差异。 - 参与公共服务治理能力建设，围绕 API key、team、model access、quota、TPM / RPM、token budget、模型映射和成本控制配置模型访问权限与限流策略。 - 定位长上下文请求下 SGLang Prefix / KV Cache 命中率异常，通过对比渲染 prompt、cached-token 日志和 token LCP，确认动态字段污染公共前缀并完成规避。 - 梳理 OpenAI / Anthropic 工具调用与流式协议差异，支持 Claude Code / Codex 类客户端经统一网关访问内部模型服务。	
Kubernetes Device Plugin 与异构加速卡平台	GPU / XPU 调度
面向国产异构加速环境的云原生资源发现、调度与验证链路。	
- 定制 Device Plugin 与资源管理链路，覆盖加速卡可用性识别、节点资源上报、容器运行时验证、卡级调度和故障隔离。 - 建设 Kubernetes AI / HPC 环境中的部署、升级、回滚和 E2E 验证流程，适配国产操作系统与异构加速卡软件栈。	

早期技术经历

亚利桑那州立大学，SNAC Lab	2020.01 - 2020.08
虚拟平台开发员 / 研究项目助理	
参与 THOTH Lab 开放式虚拟实验平台开发，扩展 SDN / OpenFlow 教学模块，并基于 Boto3 / REST API 实现 AWS 实例远程控制；曾实现 Android 端网络安全系统原型。	

教育背景

亚利桑那州立大学	2019.05 - 2020.12
计算机科学硕士，GPA 3.97 / 4.00	
亚利桑那州立大学	2015.08 - 2019.05
计算机科学本科	

知识产权

- 参与授权发明专利 2 项、授权软件著作权 2 项。